

📅 一周入职

✉ Raoniaaaa@gmail.com

☎ 17551635652

📍 上海市闵行区

🌐 [个人博客](#)

冉芸侨

AI Agent 应用开发工程



专业技能

- **AI Agent 应用开发**: 熟练掌握 Spring AI、LangChain4j 等 AI 应用框架, 具备从零设计 Agent 工作流、角色职责、上下文传递及结果校验机制的能力; 能够集成国内外主流大模型, 完成金融投研、品牌 GEO 等垂直领域 AI 应用落地。
- **Agent 工作流与业务编排**: 具备复杂 Agent 任务拆解与状态编排经验, 能够将业务流程划分为数据采集、知识清洗、分析推理、结果审校及报告生成等阶段; 熟悉任务状态持久化、数据血缘校验、失败重试、断点续跑和异步任务恢复, 保障长链路 Agent 任务稳定执行。
- **RAG 检索增强生成**: 深入理解文档解析、语义分块、Embedding、向量检索及上下文构建流程; 熟练使用 PostgreSQL/pgvector 与 BGE-M3 搭建垂直领域知识库, 具备多格式文档解析、重叠分块、HNSW 索引、知识冲突隔离、来源追踪及检索降噪经验。
- **MCP Server 与 Tool Calling**: 深入理解 Model Context Protocol, 具备从零开发 MCP Server 的能力; 能够独立完成 Tool Schema、参数校验、Handler 注册、工具路由、标准错误封装及结构化结果返回, 熟悉 Stdio、Streamable HTTP 与业务 Gateway 等多种接入方式; 可将模型问答、社交媒体采集、设备管理和第三方业务服务封装为标准化 MCP Tools。
- **跨端 MCP 与自动化执行**: 具备浏览器端与 Android 真机端 MCP 开发经验, 能够使用 TypeScript、Playwright/Puppeteer、Chromium、Camoufox 及 .NET、ADB、UIAutomator 构建跨端工具执行层; 实现过网页/App 自动交互、登录态持久化、动态 DOM/UI 解析、回答与信源提取, 以及不同执行终端之间的统一协议兼容。
- **多账号、多设备与集群调度**: 具备多账号浏览器和动态移动设备池调度经验, 实现过 Least-Active 选择、单资源独占租约、等待队列、失败换号/换机、冷却状态和自动恢复; 熟悉 Redis NX 分布式租约、Lease 续期、节点心跳、Home Node 绑定及跨节点转发, 能够支撑 MCP 服务由单机向多节点集群扩展。
- **多模型调度与并发治理**: 具备多模型统一接入和动态路由经验, 能够针对不同模型配置调用比例、超时、重试及并发策略; 实现过任务级公平限流、全局并发控制、执行 Checkpoint、结果缓存、429 冷却及失败补偿, 提升多租户高并发场景下的资源利用率与系统稳定性。
- **Prompt Engineering 与结构化输出**: 熟练运用 Role Prompt、Few-shot、CoT、约束指令及 JSON Schema 等策略设计垂直领域提示词; 具备 Prompt 版本化、运行时动态加载、结构化输出校验及自动修复重试经验, 可提升模型指令遵循率和复杂任务执行成功率。
- **大模型幻觉与内容安全治理**: 具备证据约束式生成经验, 通过引用编号校验、数据血缘控制、敏感表达检测、无引用数字拦截及多轮语义审校降低模型幻觉; 能够构建“证据检索—内容生成—确定性校验—自动改稿—发布门禁”的完整内容生产链路。
- **Java 与响应式后端开发**: 熟练掌握 Java、Spring Boot 2.x/3.x、Spring MVC 及 WebFlux, 扎实掌握 OOP、集合框架、线程池、CompletableFuture 和虚拟线程等并发模型; 具备高内聚、低耦合业务系统设计及异步任务编排能力。

- **多语言服务开发**：具备 Go/Gin、Node.js/Express、TypeScript及 .NET/[ASP.NET](#) Core服务开发经验，能够根据业务场景设计 Agent服务、MCP Server、BFF及平台 API；熟悉 Goroutine、Context、WaitGroup、SemaphoreSlim和 CancellationToken等并发机制，具备跨语言服务协作能力。
- **数据库与数据工程**：熟练使用 MySQL、PostgreSQL及 pgvector，掌握事务、索引设计、执行计划和 SQL调优；具备 JSONB、向量字段、HNSW索引、幂等键、任务租约及多租户数据隔离设计经验，能够支撑知识库、异步任务、账号元数据和计费流水等复杂数据场景。
- **商业化平台与工程治理**：具备多租户 SaaS、API Key鉴权、RBAC、BFF、白标交付及双层钱包设计经验；能够实现动态定价、成功后结算、幂等扣费、失败退款、用量审计和租户级限流，推动 AI能力从功能原型走向可运营、可计费的商业化服务。
- **缓存、消息与可观测性**：熟悉 Redis缓存、分布式锁及缓存穿透/击穿/雪崩治理方案，了解 RabbitMQ消息持久化、ACK、重试及死信队列机制；具备运行时状态、任务审计、结构化日志、SignalR实时日志及 Prometheus指标设计经验，可提升分布式 Agent与 MCP服务的可观测性。

项目经历

GEO-ServiceAgent开发2026/07 - 至今

基于 **Go 1.26 + Gin + Node.js/Express + PostgreSQL/pgvector + MySQL** 构建面向品牌方与营销机构的 GEO（Generative Engine Optimization）AI Agent 平台。系统以 **多阶段 Agent workflow编排、MCP 舆情采集、多模型可见度监控、RAG 品牌知识库及证据约束内容生产**为核心，贯通“品牌诊断 → 小红书舆情采集 → 评论清洗 → QRW 生成 → 探针问题构建 → 多模型监控 → GEO 报告 → 内容生产与媒体发布”的全链路品牌优化闭环；支持 DeepSeek、豆包、通义千问、Kimi 等模型，并提供多租户白标交付、分级鉴权、双层钱包和成功后计费能力。

多阶段 Agent workflow与数据血缘控制（Agent Workflow Orchestration）

- 设计品牌 GEO 初始化与日常优化 workflow，将复杂任务拆分为 MCP 采集、评论清洗、舆情分析、QRW 生成、探针构建、多模型监控和最终报告等阶段，通过持久化状态机统一管理阶段状态、执行进度及失败恢复；
- 建立严格的数据血缘校验机制，确保分析结果、QRW、探针、监控任务和最终报告均关联同一版本的上游数据；发现旧版本结果或 workflow 缺失时主动阻断下游任务，避免新旧数据串用；
- 实现 workflow 级取消与失效控制，新任务启动时能够终止旧的 MCP、监控及报告任务，防止异步协程继续写入过期结果；
- 将提示词以 JSON 文件和 MySQL 数据表双重管理，服务启动时自动同步 Prompt，并按照 prompt_key + active version 动态加载，使模型、JSON Schema及提示词策略可独立迭代，无需修改业务代码。

MCP 舆情采集与自适应样本补全（MCP Crawling & Adaptive Sampling）

- 通过统一 MCP Gateway 接入小红书搜索、笔记详情与评论采集工具，完成“关键词规划 → 多轮搜索 → Feed 详情抓取 → 评论落库”的两阶段异步采集流程；
- 基于品牌词、品类词和模型生成结果规划 8–12 组采集 Query，并通过多轮采样、Feed 去重、抓取上限和有效评论目标控制样本规模；当有效评论不足时自动扩大搜索范围并执行补采；
- 使用 Goroutine 与可配置并发度并行抓取 Feed 详情，在数据库中记录批次、Feed、评论和阶段级进度，为前端提供可轮询的任务进度及单条数据状态；

- 建立品牌级、Feed 级评论缓存及 TTL 复用机制，避免初始化和日常优化流程重复抓取同一内容，降低外部 MCP 调用量与任务等待时间；
- 针对外部工具超时、结果为空及采集失败构建恢复策略，通过 Query Recovery、失败批次记录和可重入任务接口提升长链路采集的稳定性。

评论清洗、QRW 分层与探针问题生成 (Data Cleaning & Query Intelligence)

- 构建 LLM 评论清洗服务，对抓取结果进行有效性判断、主题提炼和真实用户问题抽取，将非结构化舆情数据转换为可供后续分析的结构化知识；
- 支持评论人工修订与删除，并将清洗后的样本作为舆情分析、QRW 和探针生成的统一可信数据源；
- 将品牌关联词拆分为品牌词、品类词、场景词、需求词等层级，通过分级生成、重复检测和结果持久化形成可追踪的 QRW 资产；
- 基于 QRW 和用户真实问题构建模型探针库，使监控问题覆盖品牌认知、产品需求、使用场景及竞品对比，而非依赖固定模板批量提问。

多模型可见度监控与混合路由 (Multi-LLM Visibility Monitoring)

- 接入 DeepSeek、豆包、通义千问、Kimi 等目标模型，通过探针问题批量检测品牌提及率、推荐倾向、竞品曝光、回答证据来源及响应延迟；
- 设计 pure/mixed 动态路由策略，可按租户、用户和模型配置 API 调用比例；先通过真实客户端采样估算品牌提及率，再将采样结果及证据注入 API 批量执行，实现监控真实性与调用成本之间的平衡；
- 对不同模型配置独立 Endpoint、模型版本、调用超时、关键词上限及采样比例，并统一封装为标准化监控结果，屏蔽不同厂商接口协议差异；
- 记录每次调用的目标模型、执行模式、问题序号、尝试次数、响应耗时、引用来源及异常信息，为最终报告提供可回溯的原始证据链。

公平并发调度、断点续跑与缓存复用 (Fair Scheduling & Fault Tolerance)

- 自研基于任务队列轮询的 fairLimiter 公平限流器，在全局并发限制下按照 Task Key 轮转释放执行槽，防止单个大批量监控任务长期占满模型调用资源；
- 同时设置全局 API 并发、单任务批次并发及单模型客户端并发，并根据当前活跃任务数动态调整执行批次，提高多租户并发场景下的资源利用率；
- 为每个“目标模型 × 探针问题”持久化执行 Checkpoint；服务重启后自动识别孤儿任务并从已成功节点继续执行，避免整批问题重新调用和重复计费；
- 建立按模型、品牌词、探针数量和路由策略生成的同日缓存 Key，可整批或按模型复用历史监控结果，显著减少重复模型请求；
- 针对超时、空响应、429、5xx 等异常实现分级重试、Retry-After 解析、全局冷却和上下文可取消等待；任务最终失败时触发幂等退款，恢复终端用户额度。

双投影 RAG 品牌知识库 (RAG & GEO Knowledge Projection)

- 基于 BAAI/bge-m3 + PostgreSQL pgvector 构建品牌级 RAG，支持 PDF、DOCX、PPTX、XLSX、TXT、Markdown、CSV、JSON 等资料解析；
- 采用 512 字符切片与 80 字符重叠策略，并将品牌、文件名和章节标题注入 Chunk 前缀；生成 1024 维向量后写入 pgvector，利用 HNSW 索引和余弦相似度完成语义检索；
- 设计“问答索引 + GEO 写作知识”双投影：同一份原始文件同时生成通用问答 Chunk，以及品牌、产品、竞品关系、用户问题、GEO 规则、文章模板、案例等结构化知识条目；

- 对上传文件执行 SHA-256 内容去重，重复资料可直接复用既有解析文本和向量结果；通过租约、后台队列和启动恢复机制处理长耗时索引任务；
- 构建知识冲突检测机制：同一实体出现不同内容时，将新条目标记为冲突并隔离出写作上下文，保留旧版有效知识，避免未经核验的信息污染内容生成；
- 自动提取 DOCX、PPTX、PDF、XLSX 中的图片资源，按内容哈希去重并写入对象存储，为后续文章配图和发布包生成提供可授权素材。

证据约束式内容 Agent 与多轮审校 (Evidence-Grounded Content Agent)

- 构建“证据检索 → 写作规划 → 初稿生成 → 确定性校验 → 语义审校 → 自动改稿 → 图片选择 → 最终发布”的异步文章生产流水线；
- 要求模型只使用已核验的品牌知识和公开证据，对每项事实绑定证据编号；资料未提供的信息明确标记为未知，禁止模型补写产品功效、业务数字及竞品结论；
- 实现最多三轮“审校—改稿”闭环，由独立审校提示词检查引用完整性、事实一致性、竞品中立性、夸大承诺和文章结构，并将每轮 Draft、Review、Revision 持久化为可追踪版本；
- 自研 GEO 内容硬门禁，检测无效证据编号、无引用数字、绝对化宣传、贬损竞品、乱码及内部 Prompt/监控口径泄漏，阻断不合规内容直接进入公开发布链路；
- 发布前自动移除内部证据标记并转换为公开参考来源，完成品牌名称规范化、文章配图和最终发布检查，实现内部可审计与外部可发布之间的数据隔离；
- 使用任务租约、进程内并发队列和启动恢复机制处理长耗时写作任务，服务异常重启后可重新接管未完成 Job。

并行结构化报告与指标权威校验 (Structured Report Generation)

- 汇总舆情分析、QRW、探针、多模型原始回答及品牌 RAG Context，生成品牌可见度、竞品格局、内容缺口和优化行动建议；
- 将最终报告拆分为 Overview、Landscape、Actions 三个独立 Section 并发生成，缩短长报告等待时间；
- 对模型输出执行 JSON 反序列化、字段完整性和业务结构校验；校验失败时携带错误信息及上一次输出自动修复重试；
- 最终提及率、模型覆盖度等量化指标以监控程序计算结果为权威来源，覆盖 LLM 自行生成的数值，防止报告中出现无法复现的统计指标；
- 将报告渲染为结构化 HTML，并保留原始报告对象、模型元数据及知识库引用，实现报告展示、审计和历史版本追踪。

多租户白标交付与成功后计费 (Multi-Tenant SaaS & Billing)

- 设计“平台运营 → Agency 管理员 → 品牌用户”三级账户体系，通过 API Key、Bearer Token、签名 Session、Tenant Context 和用户级品牌权限实现多租户数据隔离；
- 采用 Backend API + BFF 架构，由 BFF 托管白标前端、隐藏平台 API Key 并代理业务请求，支持不同 Agency 独立域名、Logo 及支付配置；
- 构建 B2B 租户钱包与 B2C 用户钱包双层计费模型，支持产品级动态定价、会员免扣、余额校验、用量流水及低余额拦截；
- 将结算动作放入业务成功事务，通过 billing_ref 建立计费幂等键，确保重复回调、断点续跑和接口重试不会重复扣费；

- 针对多模型监控等长任务实现“成功结算、失败退款、Checkpoint 恢复不重复计费”，保证 Agent 执行状态与资金流水一致；
- 建立租户与客户端 IP 双维度限流、支付回调验签、Webhook、媒体等级定价和发布工单机制，支撑平台商业化和渠道白标交付。

跨端 MCP 智能自动化与多模型接入平台 主要开发 2026/07 - 至今

基于 TypeScript + Model Context Protocol SDK + Express + Playwright/Puppeteer + Camoufox + Redis 与 .NET 10 + [ASP.NET](#) Core + ADB/UIAutomator 构建跨端 MCP 智能自动化平台。系统同时支持浏览器网页端与 Android 真机端，将主流 AI 平台问答、社交媒体内容采集、信源提取、账号管理、设备调度及批量监控能力封装为标准化 MCP Tools，并通过统一 Gateway 对外提供一致的工具协议。平台支持 Stdio、Streamable HTTP、多账号路由、动态设备池、Redis 集群协调及失败自动切换，可作为上层 AI Agent、工作流引擎和业务系统的通用工具执行层。

MCP Tool 标准化设计与多协议接入 (MCP Server & Tool Architecture)

- 基于官方 MCP SDK 独立实现 MCP Server，完成 Tool 定义、参数描述、Schema 校验、Handler 动态注册及标准化结果封装；
- 使用 Zod 及 .NET Attribute 分别构建 TypeScript、C# 两套 Tool Schema，实现工具参数、只读属性、可选字段及默认值的强类型约束；
- 同时提供 Stdio MCP、Streamable HTTP MCP 和业务 Gateway 接口，兼容本地 Agent 客户端、远程服务及自动化工作流调用；
- 将工具元数据与执行 Handler 解耦，集中管理工具名称、描述和参数定义，新增目标网站或业务工具时只需实现 Adapter 并完成注册；
- 统一浏览器端与移动端核心问答工具的请求和响应契约，使上层 Agent 无需感知实际执行环境即可动态选择浏览器或 Android 真机。

浏览器自动化适配器与双引擎架构 (Browser Automation MCP)

- 设计统一 BrowserProvider 抽象，同时适配 Chromium 与 Camoufox 浏览器引擎，屏蔽不同浏览器在启动、连接、页面操作及状态持久化方面的差异；
- 基于目标类型构建独立 Adapter，将主流 AI 网页端及社交媒体平台的登录、搜索、内容详情、评论加载、问答和信源获取封装为 MCP Tools；
- 针对动态页面实现输入框定位、消息发送确认、回答稳定性检测、Prompt 回显过滤、加载状态识别及动态 DOM 数据抽取；
- 自研人类行为模拟组件，通过随机鼠标轨迹、点击偏移、滚动节奏及操作间隔降低自动化行为的机械特征；
- 为社交媒体采集实现“搜索—筛选—打开内容—提取正文—滚动评论—关闭详情”的原子化工具流程，并支持结果去重、排序、采集上限和排除列表；
- 建立验证码、登录过期、访问受限、代理异常等账户运行状态模型，出现风险状态时自动停止当前任务并切换可用账号。

Android 真机 MCP 网关 (Mobile MCP Gateway)

- 基于 .NET 10 与 [ASP.NET](#) Core MCP Server 构建移动端工具网关，通过 ADB 和 UIAutomator 控制 Android 真机上的主流 AI 应用；
- 将设备注册、无线 ADB 配对、连接刷新、设备移除、模型提问和运行状态查询等能力封装为标准 MCP Tools；

- 实现 App 启动、会话初始化、输入框定位、提示词写入、发送状态确认、回答完成检测及文本抽取的完整自动化流程；
- 针对不同移动端应用建立配置化 UI Profile，通过文本标记、Resource ID、坐标及页面层级组合定位交互控件，降低界面变动造成的适配成本；
- 支持从回答页面、信源面板和会话分享结果中多路径提取来源链接，并对内部跳转地址、重复链接和无效来源进行过滤；
- 保持与浏览器端工具相同的核心参数和返回结构，实现网页端与真机端执行能力互补。

多账号、多设备资源调度 (Account & Device Scheduling)

- 建立账号注册中心与动态设备注册表，统一维护目标类型、账号标识、Session、节点归属、登录状态和运行状态；
- 实现 Random与 Least-Active 资源选择策略，请求未指定账号时自动从 Enabled且 Ready 的资源池中选择负载较低的执行实例；
- 为每个浏览器 Session和移动设备建立独占租约，使用队列及信号量串行化同一资源上的操作，防止并发请求同时修改同一页面或 App；
- 当目标账号或设备执行失败时，记录已尝试资源并自动切换其他可用实例，避免失败任务持续命中同一异常资源；
- 支持 Busy Wait、排队上限、冷却时间和资源状态回写，使资源不足时能够等待恢复或返回可诊断的标准错误。

Redis 集群协调与跨节点路由 (Distributed MCP Cluster)

- 基于 Redis NX Lock实现跨节点 Session 互斥，使用随机 Token保证租约只能由持有者释放；
- 实现租约 TTL与自动续期机制，防止长耗时网页操作期间锁提前过期，同时避免异常节点永久占用资源；
- 为每个账号维护 Home Node和节点直连地址，使持有本地浏览器 Profile的请求能够被准确路由至对应节点；
- 支持本地文件、PostgreSQL和 MySQL等账号元数据存储方式，并将持久化元数据与 Redis运行时协调状态分离；
- 提供内置 Gateway完成账号选择、节点发现和跨节点请求转发，使调用方只需访问统一入口，无需了解浏览器实际运行位置。

批量监控任务与故障恢复 (Batch Monitoring & Recovery)

- 将批量问题及 Excel 文件封装为异步 MCP任务，提交后立即返回 Job ID，并提供进度查询、结果获取和任务取消工具；
- 基于后台任务队列并行调用动态设备池，将每行问题的回答、信源、状态及错误信息持久化；
- 服务启动时自动扫描处于 Queued或 Running 状态的未完成任务，将中断任务重新放回队列继续执行；
- 支持通过回调接口将批任务完成结果推送至外部自动化 workflow，实现 MCP工具与业务流程编排平台的集成；
- 通过 CancellationToken、超时控制、失败重试及资源 Lease回收，确保任务取消或异常退出后设备能够恢复为空闲状态。

运行监控与管理平台 (Observability & Operations)

- 提供浏览器运行时、Session列表、账号状态、节点路由、设备池状态及等待请求数量等 MCP查询工具；
- 建立企业级任务审计模型，记录 Request ID、Job ID、账号、节点、执行耗时及错误类型，便于定位跨节点调用问题；
- 输出 Prometheus运行指标，并提供浏览器账户和移动设备管理后台，支持新增、停用、预登录、恢复和运行状态查看；
- 对外隐藏 Cookie、CDP地址、Profile路径等敏感数据，同时通过 Token限制管理接口访问范围，提升 MCP服务的安全性与可运维性。

技术栈： TypeScript、Node.js、Model Context Protocol SDK、Express、Zod、Playwright/Puppeteer、Chromium、Camoufox、Redis、PostgreSQL、MySQL、React、.NET 10、[ASP.NET](#) Core、ADB、UIAutomator、Entity Framework Core、SQLite、SignalR、Vue 3

MediCore·智枢 —— 医疗业务编排与 AI Agent 融合平台

核心后端Agent开发

2026/01 - 2026/07

- **医疗业务流程引擎与SaaS架构：**基于 **Flowable 6.8 + LiteFlow** 搭建“审批流+业务规则”双流引擎，将原本硬编码的医保报销审核、处方流转等复杂逻辑解耦为可视化编排节点，使新租户接入配置周期从 5 天缩短至 1 天；设计并落地多租户 SaaS 架构，通过 Schema 级数据隔离与动态合同配置模块，支撑 3 家医院集团的独立部署与个性化业务定制。
- **AI Agent 医疗场景工程化落地（内部效能工具）：**针对客服与运营团队每日处理大量重复性医保政策咨询、诊疗指南查询的痛点，主导设计并落地基于 **Spring AI** 的内部智能问答助手，日均拦截人工咨询 200+ 次，准确率达 92%。
 - **高可信医疗 RAG 知识库构建：**摒弃通用文档切分策略，针对《医保药品目录》《中医诊疗指南》等结构化/半结构化文档，设计“按证型-方剂-禁忌”三级语义分块方案；采用 **text-embedding-v3 (通义千问) + pgvector** 构建向量库。在检索链路中，通过 **HybridSearch** 并行执行向量相似度检索与 BM25 关键词检索，利用 RRF (Reciprocal Rank Fusion) 算法融合双路结果；引入 **bge-reranker-v2-m3** 对 Top-K 候选集进行精排，并结合元数据过滤（如限定特定医保统筹区、生效日期）精准召回；强制启用答案溯源引用机制，确保每条回复均标注原文出处章节，使医保报销规则类问答幻觉率从 35% 降至 4% 以下。
 - **Tool Calling 驱动的业务数据实时交互：**将现有医保结算查询、患者医嘱历史、药品库存等 8 个核心 REST API 封装为标准 **Function Calling** 工具链；通过 JSON Schema 严格定义入参出参类型，使 AI 能够自主解析用户自然语言意图（如“查一下张三上周的医保报销明细”），调用本地服务获取实时数据并以结构化表格形式返回前端，彻底解决大模型知识滞后问题。
 - **医疗合规安全与多轮记忆持久化：**基于 **Spring AI Advisors** 构建三层拦截管道：请求层实现患者姓名/身份证/病历号等 PHI 信息的正则脱敏；响应层集成敏感词库过滤非合规诊疗建议。会话层通过 PersistentChatMemoryStore + Redis 实现多轮对话上下文持久化，以 tenantId:userId:sessionId 为 Key 存储消息窗口，支持跨请求的“追问用药禁忌”等连续交互场景；利用 **MCP 协议** 统一工具注册与调用规范，为后续接入更多医疗信息系统预留标准化扩展接口。

工作经验

上海经创贺联信息技术有限公司	全栈开发工程师	2026/01 - 2026/07
成都龙薇网络科技有限公司	全栈开发	2025/04 - 2025/12

教育经历

重庆城市科技学院（本科）	物联网工程 · 本科	2022/09 - 2026/06
• Java、Python、数据结构与算法、计算机网络、物联网、数据库原理与应用		